

Etapa 2: Comprensión y preparación de datos

Mariana Hernández Jiménez | A00841920

Andrea Estefanía De la Peña Contreras | A00840973

Carolina Navarro Barrón | A00839486

Annette Abigail Choque Millán | A00842260

Maricarmen Terán Maturino | A00841435

2025-10-08

Objetivo del análisis

El objetivo de la investigación en esta segunda etapa es observar y caracterizar las variables obtenidas en las bases de datos para relacionarlas con la pregunta de investigación: ¿Cómo influyen el nivel educativo, la condición de actividad económica, el sexo y la edad en el gasto en libros y la cantidad de libros leídos por adultos mexicanos que reportan leer por gusto?

Para lograr este objetivo, se aplicarán técnicas estadísticas descriptivas, incluyendo medidas de tendencia central, dispersión y posición para las variables cuantitativas, así como tablas y gráficos para las variables categóricas (boxplots, histogramas, análisis de correlación, etc). Todo lo anterior en un rango de los años 2022 a 2024 para conocer los datos más actuales de esta problemática.

Descripción de las variables y sus características estadísticas

Dimensión del conjunto de datos

Como se mencionó, se utilizaron las bases de datos del Módulo de Lectura (MOLEC) correspondientes a los años 2022, 2023 y 2024. Cada base anual contiene 108 variables y un número de registros que oscila entre 1,996 y 2,016 observaciones. Tras seleccionar únicamente las 7 variables de interés (nivel, cond_act, sexo, edad, p4, p7_3, p5) y aplicar los criterios de filtrado y limpieza descritos a continuación, se obtuvieron las siguientes dimensiones:

Table 1: Dimensiones de las bases de datos

Año	Registros iniciales	Registros tras filtrado
2022	2016	140
2023	1996	135
2024	2016	115

Filtrado en los datos

Para poder tener bien definidas las variables puntuales que se usarán en la investigación, se filtraron ciertos datos, por ejemplo:

- En la encuesta, los valores como “b” y códigos como 99 o 999999 indican “no sabe”, “no especificado” o “no aplica”. Estos se consideraron datos inválidos para el análisis.
- En el caso de la pregunta 5, solo se conservaron los registros donde p5=4 (“lee por gusto”), ya que el objetivo se centra en la lectura voluntaria.

Descripción de las variables

La Tabla 2 presenta las variables seleccionadas, su tipo, descripción y valores posibles antes del filtrado (2022–2024)

Table 2: Descripción de variables

Nombre	Tipo	Descripción	Valores que puede tomar
nivel	Categórica	Nivel educativo alcanzado por el encuestado	00 = Ninguno 01 = Preescolar 02 = Primaria 03 = Secundaria 04 = Preparatoria o bachillerato 05 = Normal básica 06 = Carrera técnica 07 = Profesional 08 = Maestría 09 = Doctorado 99 = No sabe b = Blanco por pase
cond_act	Categórica	Condición de actividad económica (ocupado, estudiante, etc.) en la última semana	01 = trabajó para obtener ingresos 02 = trabajó sin pago ayudando en el negocio o actividad que desempeña un familiar 03 = no trabajó, pero sí tenía trabajo 04 = buscó trabajo 05 = esta en espera de que le resuelvan una solicitud de un trabajo al que acudió 06 = es estudiante 07 = se dedica a los quehaceres de su hogar 08 = es jubilado(a) o pensionado(a) 09 = esta incapacitado(a) permanentemente para trabajar 10 = Otra situación 99 = No especificado

Nombre	Tipo	Descripción	Valores que puede tomar
sexo	Categórica	Sexo del encuestado	1 = Hombre 2 = Mujer
edad	Cuantitativa	Edad del encuestado en años cumplidos	18 - 98
p7_3	Cuantitativa	Monto gastado en libros en los últimos 12 meses	b = Blanco por pase 000030 = 01-5000 (pesos) 999999 = No sabe
p4	Cuantitativa	Número de libros leídos en los últimos 12 meses	01 - 70 = Libros b = Blanco por pase
p5	Categórica	Motivo principal de lectura	1 = Por trabajo 2 = Por estudio 3 = Por cultura general o por estar al día 4 = Por gusto o por entretenimiento 5 = Por religión 6 = Otro b = Blanco por pase

scatterplot

Exploración de los datos

En la primera etapa del estudio se definieron las variables de análisis que permitirán dar respuesta a la pregunta de investigación. Estas corresponden al nivel educativo alcanzado por el encuestado, la condición de actividad económica en la última semana, el sexo, la edad en años cumplidos, el monto gastado en libros durante los últimos 12 meses, el número de libros leídos en el mismo periodo y el motivo principal de lectura. A partir de la exploración y análisis de estas variables, fue posible identificar tendencias generales y características estadísticas que se presentan a continuación (Tabla 3).

La edad de los encuestados se distribuye de manera bastante estable a lo largo de los tres años. La media se mantiene cercana a 42 años, con una mediana de 39–41 años, lo que indica que la mayoría de la población se concentra en la adultez media, con un descenso gradual hacia edades más avanzadas. Estadísticamente, la distribución de la edad se comporta de forma aproximadamente normal, con ligeros sesgos hacia edades mayores pero sin cambios significativos entre los distintos años.

El gasto anual en libros presenta un patrón muy marcado y constante: la mayor parte de los adultos no reporta haber destinado recursos a la compra de libros, lo que se refleja en una mediana en cero en todos los años. Sin embargo, existe un grupo reducido de individuos que sí invierte grandes cantidades, generando valores atípicos que elevan la media y producen distribuciones altamente asimétricas.

El número de libros leídos también mantiene un comportamiento estable a lo largo de los años: La mediana es de 2–3 libros al año, mientras que la media oscila entre 3.6 y 4.6 libros. La mayoría de los encuestados reporta no haber leído ningún libro en el último año, mientras que unos pocos casos concentran los valores más altos. Esto provoca distribuciones sesgadas hacia la derecha, con gran concentración en valores bajos y la presencia de lectores intensivos como casos atípicos. Al igual que en el gasto, el patrón se repite

año con año, lo que sugiere que los hábitos de lectura por gusto se mantienen reducidos en la población general.

Las variables cualitativas (que abarcan nivel educativo, condición de actividad económica, sexo y motivo de lectura) aportan el contexto sociodemográfico y no muestran cambios sustanciales entre los distintos años. El nivel educativo se concentra en educación básica y media, con baja representación de posgrados; la condición de actividad económica refleja mayor presencia de personas que trabajan o estudian; el sexo se mantiene con proporciones similares entre hombres y mujeres; y el motivo principal de lectura filtrado en este estudio asegura que el análisis se enfoque en quienes leen por gusto, evitando confusión con lecturas por obligación laboral o escolar.

Estos patrones se repiten año tras año, lo que sugiere que los hábitos de lectura por gusto siguen siendo limitados en la población general, a pesar de los esfuerzos institucionales por fomentarlos.

Interpretación de los gráficos

Las variables cuantitativas fueron analizadas y representadas por gráficos como los boxplots mostrados en las Gráficas 1, 2 y 3, las cuales muestran el comportamiento de la edad, libros leídos en los últimos doce meses y el dinero gastado en la lectura. En los tres boxplots observamos que la edad presenta una distribución concentrada en valores bajos, también cabe mencionar que no hay valores atípicos significativos y que a través de esos tres años la mediana se mantiene estable. Cuando vemos en los gráficos la variable p4 nos referimos a la cantidad de libros leídos en los últimos doce meses, en este caso vemos que en los tres años se concentra en valores bajos, lo que puede significar poco interés en la lectura debido a la poca cantidad de libros leídos por las personas, la mediana es baja y no notamos un cambio a través de los años sino que se mantiene estable. La variable p7_3 representa la cantidad de dinero gastado en libros y en este caso al analizar los boxplots podemos observar mayor dispersión y datos atípicos y un ejemplo de ello es en 2022 donde se observan datos atípicos significativos de gasto de hasta 120 mil. En el caso de 2023 y 2024 aún notamos dispersión en los datos, disminuye pero muestra asimetría positiva.

Ahora, planteamos la información en forma de un histograma. Analizando la distribución de edad de la población (Véase la Gráfica 4), se muestra una concentración notable en el rango de adultez media (20 a 30 años), con una disminución progresiva hacia las edades mayores. Esto nos da a entender que hay una distribución normal con ligera asimetría a la derecha, lo que sugiere que la mayoría de la población que lee son adultos jóvenes o de mediana edad. Por otro lado, tenemos el histograma de Gasto anual en libros (Véase la gráfica 5). Analizando, podemos observar una distribución altamente asimétrica y concentrada en valores cercanos a cero. La gran mayoría de la población reporta no haber destinado recursos económicos en la compra de libros. Sin embargo, se observa que hay una pequeña cantidad de la población que invierte en cantidades elevadas. Esto sugiere que hay una minoría que mantiene la lectura como una práctica activa, mientras que la mayoría no suele practicar esta actividad.

Analizando el siguiente histograma de los libros leídos en el periodo anual de 2022 (Véase la Gráfica 6), podemos observar que nuevamente tenemos una distribución bastante asimétrica, similar a la Gráfica 5. La mayoría de la población se mantiene en 0 a 5 libros leídos al año, mientras que una minoría lee de 5 hasta 40 libros en un año, pero es una cantidad muy pequeña de la población. Con esto, podemos concluir que la mayoría de la población no tiende a leer, mientras que hay una pequeña minoría que lee cantidades grandes de libros.

Analizando las gráficas de 2023 podemos notar que en el caso de la Gráfica 7 gran parte de las edades se encuentran en las personas entre 25 y 50 años, vemos que se parece un poco a una distribución normal asimétrica hacia la derecha, muy diferente a lo que observamos en las gráficas de las otras variables, pues en la gráfica que representa el gasto en la lectura en 2023, Gráfica 8, vemos un claro sesgo a la derecha lo que significa que la mayoría de las personas encuestadas gasta poco o nada en la lectura, aquí notamos algo peculiar pues al mismo tiempo la gráfica que muestra la cantidad de libros leídos en los últimos doce meses, Gráfica 9, esta sesgada igualmente a la derecha con la mayor parte de las respuestas entre 0 y 5 libros leídos al año, vemos que se trata de una distribución desigual. pero encontramos una relación pues vemos que así como se gasta poco en la lectura también se leen pocos libros.

Analizando el histograma de edad para la Gráfica 10, podemos observar que es una distribución relativamente normal, mostrándose una concentración en las edades de 20 a 40 años. Esto sugiere que la población en el periodo anual de 2024 que leen van desde los 20 hasta los 40 años, viendo una disminución progresiva cuando va aumentando la edad.

Ahora, observemos el Gasto en la lectura que se tiene para el año 2024 (Véase la Gráfica 11). Podemos observar que una gran mayoría de la población no tiene destinados gastos a la lectura, con una frecuencia que va disminuyendo cuando el gasto aumenta. Esto propone que la mayoría de la población no tiene destinados sus gastos a la lectura.

Conclusión

Se ha completado la etapa exploratoria del análisis descriptivo, identificando patrones generales sobre los hábitos de lectura en México y las variables que los influyen. El trabajo permitió seleccionar y depurar las variables clave (nivel educativo, condición económica, sexo, edad, gasto en libros y número de libros leídos), así como generar gráficos que evidencian distribuciones sesgadas y concentraciones en adultos de edad media. Los resultados sugieren que el gasto en libros y la lectura por gusto son prácticas minoritarias, posiblemente relacionadas con factores educativos y económicos, lo que sienta las bases para formular hipótesis inferenciales como: - Las personas con mayor nivel educativo gastan más en libros. - El número de libros leídos varía según la condición económica. - Existen diferencias de género en el comportamiento lector.

Anexos

Link del repositorio en github (docs/quarto/reports):


https://github.com/AnnetteChoque/A00842260_ModelacionEstadistica.git

Table 3: Medidas descriptivas.


Estadística	edad_22	p7_3	p4	edad_23	p7_3	p4	edad_24	p7_3	p4
Media	41.76	1745.01	4.56	42.73	797.44	3.64	41.42	867.12	3.72
Mediana	38	500	3	41	500	3	39	500	2
Rango	49.5	60005	23	48.5	2010	15.5	51	2515	25.5
Medio									
Desviación	16.43	10183.49	7.28	15.49	838.11	3.58	15.07	1045.49	5.23

Estadística	edad_22	p7_3	p4	edad_23	p7_3	p4	edad_24	p7_3	p4
CV	39.34	583.58	159.77	36.26	105.10	98.43	36.37	120.57	140.5
Q1	27	247.5	2	29	245	2	30	300	2
Q2	38	500	3	41	500	3	39	500	2
(Mediana)									
Q3	56	925	4	53.5	1000	4.5	52	1000	4
Sesgo	0.51	11.19	3.82	0.46	1.91	3.77	0.61	2.55	6.35
Curtosis	2.06	129.89	17.88	2.31	6.46	24.26	2.46	9.71	54.06


Boxplots 2022






Gráfica 1. Boxplot Variables 2022






Gráfica 2. Boxplot Variables 2023



Gráfica 3. Boxplot Variables 2024


Histograma de edad 2022:**Histograma de p7_3 2022:****Histograma de p4 2022**

Gráficas 4,5,6. Histogramas de las variables edad,p7_3 (Gasto en la lectura) y p4 (Libros leídos) en 2022.


Histograma de edad 2023:**Histograma de p7_3 2023:****Histograma de p4 2023**

Gráficas 7,8,9. Histogramas de las variables edad,p7_3 (Gasto en la lectura) y p4 (Libros leídos) en 2023.


Histograma de edad 2024



Histograma de p7_3 2024



Histograma de p4 2024



Gráficas 10,11,12. Histogramas de las variables edad,p7_3 (Gasto en la lectura) y p4 (Libros leídos) en 2024.