

Etapa 2: Comprensión y preparación de datos

Mariana Hernández Jiménez | A00841920

Andrea Estefanía De la Peña Contreras | A00840973

Carolina Navarro Barrón | A00839486

Annette Abigail Choque Millán | A00842260

Maricarmen Terán Maturino | A00841435

2025-10-08

Objetivo del análisis

El objetivo de la investigación en esta segunda etapa es observar y caracterizar las variables obtenidas en las bases de datos para relacionarlas con la pregunta de investigación: ¿Cómo influyen el nivel educativo, la condición de actividad económica, el sexo y la edad en el gasto en libros y la cantidad de libros leídos por adultos mexicanos que reportan leer por gusto?

Para lograr este objetivo, se aplicarán técnicas estadísticas descriptivas, incluyendo medidas de tendencia central, dispersión y posición para las variables cuantitativas, así como tablas y gráficos para las variables categóricas (boxplots, histogramas, análisis de correlación, etc). Todo lo anterior en un rango de los años 2022 a 2024 para conocer los datos más actuales de esta problemática.

Descripción de las variables y sus características estadísticas

Dimensión del conjunto de datos

Como se mencionó, se utilizaron las bases de datos del Módulo de Lectura (MOLEC) correspondientes a los años 2022, 2023 y 2024. Cada base anual contiene 108 variables y un número de registros que oscila entre 1,996 y 2,016 observaciones. Tras seleccionar únicamente las 7 variables de interés (nivel, cond_act, sexo, edad, p4, p7_3, p5) y aplicar los criterios de filtrado y limpieza descritos a continuación, se obtuvieron las siguientes dimensiones:

Table 1: Dimensiones de las bases de datos

Año	Registros iniciales	Registros tras filtrado
2022	2016	140
2023	1996	135
2024	2016	115

Filtrado en los datos

Para poder tener bien definidas las variables puntuales que se usarán en la investigación, se filtraron ciertos datos, por ejemplo:

- En la encuesta, los valores como “b” y códigos como 99 o 999999 indican “no sabe”, “no especificado” o “no aplica”. Estos se consideraron datos inválidos para el análisis.
- En el caso de la pregunta 5, solo se conservaron los registros donde p5=4 (“lee por gusto”), ya que el objetivo se centra en la lectura voluntaria.

Descripción de las variables

La Tabla 2 presenta las variables seleccionadas, su tipo, descripción y valores posibles antes del filtrado (2022–2024)

Table 2: Descripción de variables

Nombre	Tipo	Descripción	Valores que puede tomar
nivel	Categórica	Nivel educativo alcanzado por el encuestado	00 = Ninguno 01 = Preescolar 02 = Primaria 03 = Secundaria 04 = Preparatoria o bachillerato 05 = Normal básica 06 = Carrera técnica 07 = Profesional 08 = Maestría 09 = Doctorado 99 = No sabe
cond_act	Categórica	Condición de actividad económica (ocupado, estudiante, etc.) en la última semana	b = Blanco por pase 01 = trabajó para obtener ingresos 02 = trabajó sin pago ayudando en el negocio o actividad que desempeña un familiar 03 = no trabajó, pero sí tenía trabajo 04 = buscó trabajo 05 = esta en espera de que le resuelvan una solicitud de un trabajo al que acudió 06 = es estudiante 07 = se dedica a los quehaceres de su hogar 08 = es jubilado(a) o pensionado(a) 09 = esta incapacitado(a) permanentemente para trabajar 10 = Otra situación 99 = No especificado

Nombre	Tipo	Descripción	Valores que puede tomar
sexo	Categórica	Sexo del encuestado	1 = Hombre 2 = Mujer
edad	Cuantitativa	Edad del encuestado en años cumplidos	18 - 98
p7_3	Cuantitativa	Monto gastado en libros en los últimos 12 meses	b = Blanco por pase 000030 - 01-5000 (pesos) 999999 = No sabe
p4	Cuantitativa	Número de libros leídos en los últimos 12 meses	01 - 70 = Libros b = Blanco por pase
p5	Categórica	Motivo principal de lectura	1 = Por trabajo 2 = Por estudio 3 = Por cultura general o por estar al día 4 = Por gusto o por entretenimiento 5 = Por religión 6 = Otro b = Blanco por pase

scatterplot

Exploración de los datos

Visualización de variables cuantitativas