

Etapa 3: Análisis Inferencial

Mariana Hernández Jiménez | A00841920

Andrea Estefanía De la Peña Contreras | A00840973

Carolina Navarro Barrón | A00839486

Annette Abigail Choque Millán | A00842260

Maricarmen Terán Maturino | A00841435

2025-10-15

Objetivo del análisis

El objetivo principal de este reporte es evaluar mediante técnicas de inferencia estadística, si ciertos factores; específicamente el nivel educativo, la condición de actividad económica y el género, tienen un impacto significativo en los hábitos de lectura de los adultos mexicanos que leen por gusto. Este análisis se centra en dos indicadores clave del comportamiento lector:

- El número de libros leídos en los últimos 12 meses, y
- El monto gastado en libros durante el mismo periodo.

A partir de los hallazgos descriptivos de la Etapa 2 que revelaron patrones estables entre 2022 y 2024, como una mediana baja de libros leídos (2–3 al año), un gasto en libros altamente concentrado en cero y una población lectora mayormente adulta con educación media o superior, se formularon tres hipótesis que serán discutidas en este análisis inferencial:

- Las personas con mayor nivel educativo gastan más en libros.
- El número de libros leídos varía según la condición de actividad económica.
- Existen diferencias de género en el comportamiento lector.

Con un nivel de significancia de $\alpha = 0.04$, se aplicarán pruebas de hipótesis e intervalos de confianza para contrastar estas afirmaciones con base en los datos de MOLEC. El propósito final es generar evidencia que permita identificar qué factores sí influyen en la lectura en México, y así contribuir para fomentar este hábito.

Pruebas de Hipótesis

Diferencia de medias

Hipótesis 1: Las personas con mayor nivel educativo gastan más en libros.

Sea μ la media

Hipótesis Nula. No existe diferencia entre el promedio de gasto en libros para diferente nivel educativo (alto y bajo)

$$H_0 : \mu_1 = \mu_2$$

Hipótesis alternativa. Que las personas con mayor nivel educativo gastan más en libros.

$$H_1: \mu_1 < \mu_2$$

Donde:

- Nivel bajo: nivel ≤ 4 (hasta bachillerato)
- Nivel alto: nivel ≥ 7 (posgrados)

Al observar los datos en la Gráfica 6 (Anexo 4), el gasto en libros está muy concentrado en cero: la mayoría de las personas no gastó nada, pero unas pocas invirtieron cantidades muy altas (incluso hasta 120,000 pesos en 2022). Esto genera una distribución muy asimétrica, con mucha dispersión.

Como se observa en la Gráfica 1 (Anexo 1), el gasto en libros presenta una distribución altamente sesgada a la derecha, con pocos valores extremos. Además, la Gráfica 6 del Anexo 4 muestra diferencias visibles en el gasto promedio entre niveles educativos.

Además, al comparar los grupos de “nivel educativo bajo” y “nivel educativo alto”, vimos que la variabilidad del gasto no es la misma entre ellos: quienes tienen más estudios muestran una mayor dispersión en sus gastos (algunos gastan mucho, otros nada), mientras que en el grupo con menos escolaridad casi todos reportan gasto cero que es nuestra hipótesis a corroborar.

Por estas razones, no se puede asumir que las varianzas fueran iguales entre los dos grupos. Por eso, se debe usar la prueba t para dos muestras independientes, que no requiere que las varianzas sean iguales y es más confiable cuando los datos están sesgados o tienen valores extremos.

Estos resultados se reflejan también visualmente en las Gráficas 6 y 7 (Anexo 4), donde se aprecia que el grupo con mayor nivel educativo presenta un gasto promedio más alto y mayor variabilidad.

Estadístico de prueba $t = -1.78067$

Valor crítico $z_f = -1.758465$

Valor $p = 0.03814393$

Como $t = -1.781 < -1.751$ y $p = 0.038 < 0.04$, hay evidencia suficiente para rechazar la hipótesis. Esto lo podemos verificar mediante la prueba de t-student, donde:

Welch Two Sample t-test

data: LI1 and LS1

$t = -1.7807$, $df = 229.71$, $p\text{-value} = 0.03814$

alternative hypothesis: true difference in means is less than 0

96 percent confidence interval:

-Inf -12.31105

```
sample estimates:
mean of x mean of y
  616.2867 1603.5318
```

En esta prueba obtenemos: $p\text{-value} = 0.03814$ y tomamos el valor de significancia como 0.04

Como el valor $p < 0.04$ entonces se rechaza la hipótesis nula y decimos que el nivel educativo si hace una diferencia en el gasto en libros.

Obtuvimos también que $t = -1.7807$ es negativo porque el gasto promedio de la clase de menor nivel educativo es menor que el promedio de los de mayor nivel educativo. Esto nos lleva a concluir que las personas con mayor nivel educativo gastan más en libros.

Hipótesis 2: El número de libros leídos varía según la condición económica

Sea μ la media

Hipótesis Nula. No hay diferencia entre la condición económica (trabaja o no trabaja) y los libros leídos.

$$H_0 : \mu_1 = \mu_2$$

Hipótesis Alternativa.

$$H_1 : \mu_1 \neq \mu_2$$

Donde:

- Trabaja: $\text{cond_act} = 1$ (trabaja para obtener ingresos)
- No trabaja: $\text{cond_act} \neq 1$ (estudiantes, jubilados, etc)

La hipótesis plantea que el número de libros leídos varía según la condición de actividad económica. Para probar esta afirmación, se compara a quienes trabajaron para obtener ingresos con el resto de la población.

Al observar los datos en los histogramas de las Gráficas 4 y 5 (Anexo 2), el número de libros leídos (p_4) está muy concentrado en valores bajos: la mayoría de las personas reporta haber leído entre 0 y 5 libros en el último año, pero hay unos pocos casos que leen mucho más (hasta 70 libros), lo que genera una distribución muy asimétrica.

Además, al comparar los dos grupos de interés, la variabilidad no es la misma entre ellos. El grupo de “no trabaja” incluye a estudiantes y jubilados, cuyos hábitos de lectura son más diversos: algunos estudiantes leen mucho por sus estudios o por gusto, mientras que otras personas en esta categoría casi no leen. Esto se refleja en una mayor dispersión en este grupo en comparación con quienes trabajan.

Por estas razones, no se puede asumir que las varianzas fueran iguales entre los dos grupos. Por lo tanto, nuevamente conviene usar la prueba t para dos muestras independientes que es confiable cuando los datos tienen valores extremos.

Esta tendencia coincide con lo mostrado en las Gráficas 4 y 5 (Anexo 2), donde la distribución de lectura varía ligeramente según la condición de actividad económica.

Estadístico de prueba $t = 1.174925$
Valor crítico $z_f = 2.053749$
Valor $p = 0.2410183$

Intervalo: [-0.5241124 , 1.910423]

Con los resultados de la prueba a mano, se obtuvo que $|t| = 1.17 < 2.054$ y $p = 0.241 > 0.04$, por lo que, siendo el estadístico menor que el valor crítico, y el valor p mayor que el nivel de significancia. No hay evidencia de que la condición económica influya en los libros leídos.

Pero también se probará con la prueba de Welch para 2 muestras, la cual obtiene:

Welch Two Sample t-test

```
data: trabaja and no_trabaja
t = 1.1749, df = 281.32, p-value = 0.241
alternative hypothesis: true difference in means is not equal to 0
96 percent confidence interval:
 -0.5241124  1.9104230
sample estimates:
mean of x mean of y
 4.230469  3.537313
```

Con esta prueba obtenemos $p\text{-value} = 0.241$ y vemos que el valor p es > 0.04 por lo tanto no hay evidencia suficiente para rechazar la hipótesis nula. Tambiene es importante notar que en el intervalo de confianza se incluye cero, lo que refuerza la idea de que no hay evidencia suficiente de una diferencia entre los libros leídos según la situación económica.

Hipótesis 3: Existen diferencias de género en el comportamiento lector.

Sea μ la media

Hipótesis Nula. No existen diferencias entre la lectura en hombres y en mujeres

$H_0 : \mu_1 = \mu_2$

Hipótesis Alternativa.

$H_1 : \mu_1 \neq \mu_2$

En este caso se intenta probar existen diferencias de género en el comportamiento lector, es decir, que hombres y mujeres podrían leer una cantidad distinta de libros por gusto.

Se compara el número de libros leídos ($p4$) entre quienes se identificaron como hombres ($\text{sexo} == 1$) y mujeres ($\text{sexo} == 2$). Al revisar los datos de los histogramas , notamos que la distribución de lectura es muy similar entre ambos grupos: en ambos casos, la mayoría reporta haber leído entre 0 y 5 libros al año, con pocos casos extremos. Esta similitud puede observarse en la Gráfica 3 (Anexo 1), donde tanto hombres como mujeres presentan patrones de lectura concentrados en valores bajos.

Dado que los tamaños muestrales son grandes y balanceados, las varianzas pueden considerarse iguales. Aunque la variable p4 es sesgada, el Teorema del Límite Central hace que la distribución de la diferencia de medias sea aproximadamente normal. Por lo que se puede usar la versión clásica de la prueba t para dos muestras independientes con varianzas iguales.

```
Estadístico de prueba t = 1.594457
Valor crítico zf = 2.053749
Valor p = 0.111648
```

Intervalo: [-0.2676614 , 2.098449]

El estadístico $|t| = 1.59 < 2.053$ y el valor $p = 0.112 > 0.04$ por lo que no se rechaza H_0 , así que no se observan diferencias significativas de género en el número de libros leídos.

De nuevo, probando con el test de la prueba t se obtiene:

Two Sample t-test

```
data:  hombres and mujeres
t = 1.5945, df = 388, p-value = 0.1116
alternative hypothesis: true difference in means is not equal to 0
96 percent confidence interval:
 -0.2676614  2.0984488
sample estimates:
mean of x mean of y
 4.518072  3.602679
```


En este caso obtuvimos un valor de $p\text{-value} = 0.1116 > 0.04$ lo cual se interpreta en que no tenemos evidencia suficiente para rechazar la hipótesis nula. También es importante notar que en el intervalo de confianza se incluye el cero, lo cual refuerza la idea de que no podemos decir que hay una diferencia significativa en el comportamiento de la lectura entre hombres y mujeres.

Anexos

Link del repositorio en github (docs/docs/quarto/reports):


https://github.com/AnnetteChoque/A00842260_ModelacionEstadistica.git

Anexo 1: Histogramas de variables cuantitativas



Gráficas 1, 2, 3. Histogramas de las variables edad, p7_3 (Gasto en libros) y p4 (Libros leídos) para el periodo 2022-2024.

Anexo 2: Histogramas por condición de actividad económica




Gráficas 4, 5. Distribución del número de libros leídos según condición de actividad económica (2022-2024).

Anexo 3: Tabla de medidas descriptivas

	Media	Mediana	R-M	Desviacion	CV	Q1	Q2	Q3	Sesgo	Curtosis
edad	42.00	40	50.5	15.69	37.35	29	40	54	0.52	2.27
p7_3	1158.14	500	60005.0	6149.18	530.95	250	500	1000	18.53	357.75
p4	3.99	3	25.5	5.62	140.69	2	3	4	4.95	32.34

Anexo 4: Comparación de gasto por nivel educativo



Gráficas 6, 7. Comparación del gasto en libros según nivel educativo (2022-2024).